

Gaussian PDMF-based Fuzzy Information Measures

1 Gaussian PDMF-based Fuzzy Information Measures

1.1 Fuzzy Entropy of Membership Function

定义函数：

$$H(\mu) = \int_0^1 [-f(x; \mu) \ln f(x; \mu) - (1 - f(x; \mu)) \ln(1 - f(x; \mu))] dx \quad (1)$$

其中

$$f(x; \mu) = \Phi\left(\tan(\pi x - \frac{\pi}{2}); \mu, 1\right). \quad (2)$$

记

$$H_0 = H(0) = 0.37026. \quad (3)$$

1.2 Sample-wise Fuzzy Entropy

对每个模糊数

$$\tilde{x}_i = \langle x_i, d_i^-, d_i^+, \mu_i^-, \mu_i^+ \rangle,$$

定义其模糊熵（样本模糊熵）：

$$E_i = \frac{1}{2H_0} \left(e^{-1/d_i^-} H(\mu_i^-) + e^{-1/d_i^+} H(\mu_i^+) \right). \quad (4)$$

Lemma 1. $0 \leq E_i \leq 1$ 。

Proof. 由于对任意 $x \in [0, 1]$ 有 $0 \leq f(x; \mu) \leq 1$ ，函数 $-t \ln t - (1-t) \ln(1-t)$ 在 $[0, 1]$ 上非负，故 $H(\mu) \geq 0$ 。当 $\mu = 0$ 时模糊性最大，因此 $H(\mu) \leq H_0$ 。又因为 $0 < e^{-1/d_i^-} < 1$ 且 $0 < e^{-1/d_i^+} < 1$ ，可得

$$E_i \leq 1,$$

且显然 $E_i \geq 0$ 。因此 $0 \leq E_i \leq 1$ 。 **proof**

1.3 Induced Measure

定义信息强度 $1 - E_i$ 。对其归一化，得到样本 i 的权重分布：

$$w_i = \frac{1 - E_i}{\sum_{k=1}^n (1 - E_k)}. \quad (5)$$

Lemma 2. $w_i \geq 0$ 且 $\sum_{i=1}^n w_i = 1$ 。

证明. 由 $0 \leq E_i \leq 1$ 知 $w_i \geq 0$ 且分母大于 0, 因此 $w_i \geq 0$, 且

$$\sum_{i=1}^n w_i = 1.$$

■

Proposition 1. 该分布满足: (1) 单调性: 若 $E_i \leq E_j$, 则 $w_i \geq w_j$; (2) 极值性质: $E_i = 0$ 时 w_i 最大, $E_i = 1$ 时 $w_i = 0$ 。

证明. (1) 由 $E_i \leq E_j$ 得 $1 - E_i \geq 1 - E_j$, 故 $w_i \geq w_j$ 。(2) 若 $E_i = 0$ 则分子为 1 (最大); 若 $E_i = 1$ 则 $w_i = 0$ 。 ■

Remark. 该构造通过将熵转化为信息强度, 并经归一化诱导出一个概率测度。该测度满足以下单调关系:

- 若 $E_i \leq E_j$, 则 $w_i \geq w_j$;
- 因而, 熵越小 (不确定性越低), 权重越大; 熵越大 (不确定性越高), 权重越小。

1.4 Attribute Entropy

定义单属性熵:

$$E(a) = - \sum_{i=1}^n w_i^{(a)} \ln w_i^{(a)}, \quad (6)$$

其中 $w_i^{(a)} \geq 0$ 且 $\sum_{i=1}^n w_i^{(a)} = 1$ 。

Proposition 2. 有

$$0 \leq E(a) \leq \ln n.$$

证明. 首先证明下界。函数 $f(x) = -x \ln x$ 在 $(0, 1]$ 上非负, 且

$$\lim_{x \rightarrow 0^+} -x \ln x = 0,$$

因此 $f(x) \geq 0$ 对 $x \in [0, 1]$ 成立, 从而

$$E(a) = \sum_{i=1}^n (-w_i^{(a)} \ln w_i^{(a)}) \geq 0.$$

其次证明上界。在约束条件 $\sum_{i=1}^n w_i^{(a)} = 1$ 下, 函数

$$E(a) = - \sum_{i=1}^n w_i^{(a)} \ln w_i^{(a)}$$

在概率单纯形上达到最大值。当且仅当

$$w_i^{(a)} = \frac{1}{n}, \quad i = 1, \dots, n,$$

时取到最大值, 此时

$$E(a) = - \sum_{i=1}^n \frac{1}{n} \ln \frac{1}{n} = \ln n.$$

证毕。 ■

1.5 Attribute Subset Entropy

对于属性子集 S ，定义样本 i 的模糊熵：

$$E_i^{(S)} = 1 - \prod_{a \in S} (1 - E_i^{(a)}). \quad (7)$$

在定义 $E_i^{(S)}$ 后，属性子集 S 的熵定义为：

$$E(S) = - \sum_{i=1}^n w_i^{(S)} \ln w_i^{(S)}.$$

其中权重分布由样本级熵诱导得到：

$$w_i^{(S)} = \frac{1 - E_i^{(S)}}{\sum_{k=1}^n (1 - E_k^{(S)})}.$$

Proposition 3. 若 $A \subseteq B$ ，则 $E_i^{(A)} \leq E_i^{(B)}$ 。

Proof. 由于 $E_i^{(a)} \in [0, 1]$ ，故 $0 \leq 1 - E_i^{(a)} \leq 1$ 。设 $A \subseteq B$ ，则

$$\prod_{a \in B} (1 - E_i^{(a)}) = \left(\prod_{a \in A} (1 - E_i^{(a)}) \right) \left(\prod_{a \in B \setminus A} (1 - E_i^{(a)}) \right).$$

由于

$$\prod_{a \in B \setminus A} (1 - E_i^{(a)}) \leq 1,$$

可得

$$\prod_{a \in B} (1 - E_i^{(a)}) \leq \prod_{a \in A} (1 - E_i^{(a)}).$$

即

$$1 - E_i^{(B)} \leq 1 - E_i^{(A)},$$

从而

$$E_i^{(A)} \leq E_i^{(B)}.$$

proof

Remark 1. 虽然 $E_i^{(A)} \leq E_i^{(B)}$ 成立，但一般不能推出 $E(A) \leq E(B)$ ，因为概率归一化会改变分布结构。

1.6 Joint Entropy

定义属性子集 A 和 B 的联合熵为

$$E(A, B) = E(A \cup B),$$

其中样本联合模糊熵满足

$$E_i^{(A \cup B)} = 1 - (1 - E_i^{(A)})(1 - E_i^{(B)}),$$

对应的权重分布为

$$w_i^{(A, B)} = \frac{1 - E_i^{(A \cup B)}}{\sum_{k=1}^n (1 - E_k^{(A \cup B)})}.$$

因此

$$E(A, B) = - \sum_{i=1}^n w_i^{(A, B)} \ln w_i^{(A, B)}.$$

Remark 2. 该定义保证了联合熵的对称性 $E(A, B) = E(B, A)$ ，并满足递归一致性：

$$E(A, B, C) = E(A \cup B \cup C) = E((A \cup B) \cup C)$$

1.7 Conditional Entropy

定义条件熵为

$$E(A|B) = E(A, B) - E(B).$$

1.8 Mutual Information

定义互信息：

$$I(A; B) = E(A) + E(B) - E(A, B).$$

2 Algorithm Design for Attribute Reduction

2.1 Internal & External Significance

为刻画单个属性在属性子集中的作用，引入内在重要性与外在重要性。

设 A 为属性子集， a 为单个属性，定义

$$\text{Sig}_{\text{in}}(a; A) = E(A) - E(A \setminus \{a\}), \quad (8)$$

$$\text{Sig}_{\text{out}}(a; A) = E(A \cup \{a\}) - E(A), \quad (9)$$

分别称为属性 a 关于 A 的 inner significance 与 outer significance。其中 $E(\cdot)$ 表示属性子集熵 (Attribute Subset Entropy)。

Remark 1. inner significance 描述从子集 A 中移除属性 a 所引起的熵变化，反映其在当前子集中的作用程度；outer significance 描述向子集 A 中加入属性 a 所带来的熵变化，刻画其补充能力。

Remark 2. 上述两类重要性本质上对应于熵函数 $E(S)$ 下的边际贡献 (marginal contribution)，其中 inner significance 对应删除操作，outer significance 对应加入操作。

Remark 3. 内在重要性与外在重要性的符号可用于判定属性的保留或剔除策略：

- 若 $\text{Sig}_{\text{in}}(a; A) > 0$ ，则移除属性 a 会降低权重分布的离散程度，使分布更加集中，因此，属性 a 有助于增强样本之间的区分结构，应予以保留。
- 若 $\text{Sig}_{\text{out}}(a; A) > 0$ ，说明引入属性 a 会提高权重分布的离散程度，使样本间的结构更加丰富。因此，属性 a 能够提供新的区分信息或补充维度，应考虑加入。

在实际应用中，通常结合阈值 $\delta > 0$ ，以增强算法对数值波动的鲁棒性。

2.2 Construction of Gaussian PDMF Fuzzy Numbers from Tabular Data

为了将原始数值型表格数据转化为 Gaussian PDMF 模糊信息系统，本节给出一种完全数据驱动的构造方法。该方法不依赖人工参数，仅基于局部邻域结构生成模糊数表示。

2.2.1 Input and Output

设 a 为一个数值属性，其取值为

$$\{x_1, x_2, \dots, x_n\}.$$

给定近邻参数 $k \in \mathbb{N}$ (通常取 $k = 3$ 或 $k = 5$)，对每个样本 x_i 构造 Gaussian PDMF 模糊数：

$$\tilde{x}_i = \langle x_i, d_i^-, d_i^+, \mu_i^-, \mu_i^+ \rangle.$$

2.2.2 Construction of Local Widths d_i^- and d_i^+

首先对属性列进行升序排序，得到有序序列：

$$x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}.$$

对排序后的第 i 个样本 $x_{(i)}$ ，定义左右邻域样本数：

$$m_L = \min(k, i - 1), \quad m_R = \min(k, n - i).$$

当左侧存在邻居 ($m_L > 0$) 时，定义左侧宽度为：

$$d_i^- = \frac{1}{m_L} \sum_{j=1}^{m_L} (x_{(i)} - x_{(i-j)}).$$

当右侧存在邻居 ($m_R > 0$) 时，定义右侧宽度为：

$$d_i^+ = \frac{1}{m_R} \sum_{j=1}^{m_R} (x_{(i+j)} - x_{(i)}).$$

对于边界情况，进行单侧补齐：

- 若 $m_L = 0$ ，则令 $d_i^- = d_i^+$ ；
- 若 $m_R = 0$ ，则令 $d_i^+ = d_i^-$ 。

为保证数值稳定性，引入下界约束：

$$d_i^- = \max(d_i^-, \varepsilon), \quad d_i^+ = \max(d_i^+, \varepsilon),$$

其中 $\varepsilon = 10^{-8}$ 。

Remark. 除边界样本外，一般有 $d_i^- \neq d_i^+$ ，从而形成非对称模糊支撑结构。

2.2.3 Construction of Membership Parameters μ_i^- and μ_i^+

为刻画模糊性的强弱，需要为每个样本构造参数 μ_i 。所有方法均满足以下原则：

- $|\mu_i|$ 越大，模糊性越低；
- μ_i 由数据自适应生成；
- 采用对称构造： $\mu_i^- = \mu_i^+ = \mu_i$ 。

下面给出三种可选的数据驱动方法。

Method A: Density-based Construction 对样本 x_i , 取其 k 近邻, 记平均距离为:

$$\text{avg_dist}_i = \frac{1}{k} \sum_{j=1}^k |x_i - x_{i_j}|,$$

其中 x_{i_j} 为第 j 个近邻。

定义局部密度为:

$$\rho_i = \frac{1}{\text{avg_dist}_i + \varepsilon}.$$

对 ρ_i 进行归一化:

$$\rho_i^{\text{norm}} = \frac{\rho_i - \min(\rho)}{\max(\rho) - \min(\rho) + \varepsilon}.$$

最终得到:

$$\mu_i = 2\rho_i^{\text{norm}} - 1,$$

并令:

$$\mu_i^- = \mu_i^+ = \mu_i.$$

Method B: Center-distance-based Construction 计算属性均值与标准差:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad \sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}.$$

定义标准化距离:

$$z_i = \frac{|x_i - \bar{x}|}{\sigma + \varepsilon}.$$

定义:

$$\mu_i = 1 - z_i,$$

并进行截断:

$$\mu_i = \max(-1, \min(1, \mu_i)).$$

最终:

$$\mu_i^- = \mu_i^+ = \mu_i.$$

Method C: Normalization-based Construction 首先对属性进行归一化:

$$x_i^{\text{norm}} = \frac{x_i - \min(x)}{\max(x) - \min(x) + \varepsilon}.$$

映射到区间 $[-1, 1]$:

$$\mu_i = 2x_i^{\text{norm}} - 1.$$

同样设:

$$\mu_i^- = \mu_i^+ = \mu_i.$$

2.2.4 Final Fuzzy Representation

综上, 对每个样本 x_i , 得到 Gaussian PDMF 模糊数:

$$\tilde{x}_i = \langle x_i, d_i^-, d_i^+, \mu_i^-, \mu_i^+ \rangle.$$

该构造方法完全基于数据分布, 能够自适应刻画局部结构与不确定性, 并为后续模糊信息度量与属性约简提供统一输入。

2.3 Algorithm Design

在算法实现过程中，涉及若干关键参数的设定。为保证方法的稳定性与可复现性，本文采用如下策略。

Construction of μ_i . 在 Gaussian PDMF 模糊数构造过程中，本文采用基于中心距离的生成方法 (Method B)。具体而言，

$$\mu_i = 1 - \frac{|x_i - \bar{x}|}{\sigma + \varepsilon},$$

并截断至区间 $[-1, 1]$ 。该方法具有数值稳定性强、对异常值不敏感等优点。

Neighborhood size k . 在局部宽度 d_i^-, d_i^+ 的构造中，近邻参数 k 控制局部结构刻画的尺度。一般取较小值以反映局部特性。本文实验中采用：

$$k \in \{3, 5\}.$$

Stability threshold δ . 在属性约简阶段，为保证约简结果在信息层面与原始属性集一致，引入稳定性约束：

$$|E(\text{red}) - E(C)| \leq \delta.$$

参数 δ 控制信息保持的精度。较小的 δ 会得到更精确但规模较大的约简集，较大的 δ 则允许更激进的约简。本文中取：

$$\delta \in [0.1, 0.2].$$

Remark. 上述参数均为数据驱动或弱依赖参数，其中 μ_i 的构造不依赖人工调节， δ 仅用于平衡约简规模与信息保持之间的权衡，因此整体方法具有较好的鲁棒性与可推广性。

Algorithm 1 基于模糊熵与重要性的属性约简算法

1: **输入:** 信息系统 (U, C)
2: 将信息系统 (U, C) 转换为 PDMF 模糊信息系统 $\tilde{U}$
3: **输出:** 约简属性集 red
4: 初始化 $red \leftarrow \emptyset$
5: 计算 $E(C)$

▷ 阶段 1: 基于外在重要性的前向选择

6: $flag \leftarrow \text{true}$
7: **while** $flag = \text{true}$ **do**
8: $flag \leftarrow \text{false}$
9: **for all** $a \in C \setminus red$ **do**
10: 计算 $\text{Sig}_{\text{out}}(a; red)$
11: **end for**
12: $a^* \leftarrow \arg \max_{a \in C \setminus red} \text{Sig}_{\text{out}}(a; red)$
13: **if** $\text{Sig}_{\text{out}}(a^*; red) > 0$ **then**
14: $red \leftarrow red \cup \{a^*\}$
15: $flag \leftarrow \text{true}$
16: **end if**
17: **end while**

▷ 阶段 2: 基于内在重要性的后向消除

18: **for all** $a \in red$ **do**
19: 计算 $\text{Sig}_{\text{in}}(a; red)$
20: **if** $\text{Sig}_{\text{in}}(a; red) \leq 0$ **then**
21: $red \leftarrow red \setminus \{a\}$
22: **end if**
23: **end for**

▷ 阶段 3: 稳定性检验与自适应修正

24: **while** $|E(red) - E(C)| > \delta$ **do**
25: $a^* \leftarrow \arg \max_{a \in C \setminus red} E(red \cup \{a\})$
26: $red \leftarrow red \cup \{a^*\}$
27: **end while**
28: **return** red

3 Experimental Results and Analysis

为验证所提出 ARPDMF 方法的有效性, 本文从分类性能、约简规模以及计算效率三个方面, 与多种经典方法 (FNRS, FRAR, IARFCIE, MFIGI, MFNMI) 进行对比分析。

3.1 Classification Performance Analysis

表 1 给出了不同方法在多个数据集上的分类准确率排名 (数值越小表示性能越好)。

表 1: Accuracy Ranking (Lower is Better)							
Dataset	ALL	ARPDMF	FNRS	FRAR	IARFCIE	MFIGI	MFNMI
Absenteeism_two	3	2	1	7	6	5	4
bridges	2	4	6	1	7	5	2
echocardiogram-0	2	6	5	7	4	1	2
flag	3	2	5	7	4	6	1
o-ring-erosion-only	1	6	3	7	4	5	1
sponge	1	2	6	4	5	7	3
transfusion	3	1	2	5	4	7	6
wdbc	2	2	6	4	5	7	1
wdbc	2	1	6	7	4	5	2
Average	2.11	2.88	4.44	5.44	4.78	5.33	2.44

从表中可以看出, ARPDMF 在多数数据集上能够取得较为优异的分类性能, 尤其在 transfusion 和 wdbc 数据集上排名第一。整体平均排名为 2.88, 优于大多数对比方法 (如 FNRS、FRAR 和 IARFCIE), 表现出较强的稳定性与泛化能力。

从平均排名来看, MFNMI (2.44) 优于 ARPDMF (2.88), 说明其在分类性能上具有一定优势。然而, 该性能提升是以显著增加计算成本为代价的。如表 3 所示, MFNMI 的平均运行时间达到 184.220 秒, 而 ARPDMF 仅为 22.423 秒, 计算开销降低约一个数量级。

因此, 尽管 MFNMI 在精度上略占优势, 但 ARPDMF 在保持较强分类性能的同时, 显著降低了计算时间, 体现出更优的效率-性能权衡, 在对计算效率敏感的实际应用场景中更具实用价值。

3.2 Reduction Size Analysis

表 2 给出了各方法的平均约简子集长度。

可以观察到, FNRS 和 FRAR 的约简子集规模整体少于部分强约简方法。然而, 这类方法通常以牺牲信息为代价进行激进压缩。

相比之下, ARPDMF 在保持较高分类性能的同时, 能够有效控制属性规模, 体现出良好的信息保持能力与约简质量之间的平衡。

3.3 Computational Efficiency Analysis

表 3 给出了各算法的运行时间对比。

从计算效率角度来看, ARPDMF 显著优于 FNRS 和 MFNMI 等方法, 其平均运行时间仅为 22.423 秒, 而 FNRS 和 MFNMI 分别达到 217.529 秒和 184.220 秒。

表 2: Average Reduction Subset Length

Dataset	ALL	ARPD MF	FNRS	FRAR	IARFCIE	MFIGI	MFNMI
Absenteeism_two	19.000	17.000	1.000	1.000	14.309	5.000	18.000
bridges	11.000	10.490	1.846	1.000	6.655	4.000	11.000
echocardiogram-0	8.000	5.938	1.763	2.900	6.709	2.100	8.000
flag	28.000	26.700	1.000	1.000	14.591	6.000	20.956
o-ring-erosion-only	3.000	2.345	1.433	2.400	2.545	2.300	3.000
sponge	23.000	22.400	1.554	1.100	6.227	6.600	14.180
transfusion	4.000	2.789	2.093	2.000	3.727	2.000	2.044
wdbc	30.000	29.140	4.079	4.500	27.364	2.000	29.934
wpbc	33.000	32.600	2.450	4.200	30.091	2.000	32.934
Average	17.667	16.600	1.913	2.233	12.469	3.556	15.561

表 3: Reduction Time (seconds)

Dataset	ALL	ARPD MF	FNRS	FRAR	IARFCIE	MFIGI	MFNMI
Absenteeism_two	0.000	26.911	122.321	0.981	22.139	2.848	198.629
bridges	0.000	9.478	5.994	0.189	2.082	0.045	1.650
echocardiogram-0	0.000	15.120	7.545	0.325	1.876	0.040	1.899
flag	0.000	16.277	16.675	0.517	6.183	0.203	30.137
o-ring-erosion-only	0.000	4.179	2.057	0.082	0.342	0.016	0.621
sponge	0.000	15.787	12.117	0.422	4.685	0.220	4.294
transfusion	0.000	14.520	171.448	0.766	14.516	1.424	55.362
wdbc	0.000	67.419	1508.755	7.024	153.868	5.937	1186.595
wpbc	0.000	32.117	110.850	2.849	17.847	0.290	178.789
Average	0.000	22.423	217.529	1.462	24.838	1.225	184.220

尽管 FRAR 和 MFIGI 在时间上更快，但其通常依赖更强的简化策略，导致分类性能或信息保持能力下降。相比之下，ARPD MF 在保证较高性能的同时，仍能维持较低的计算开销，体现出良好的效率-性能折中。